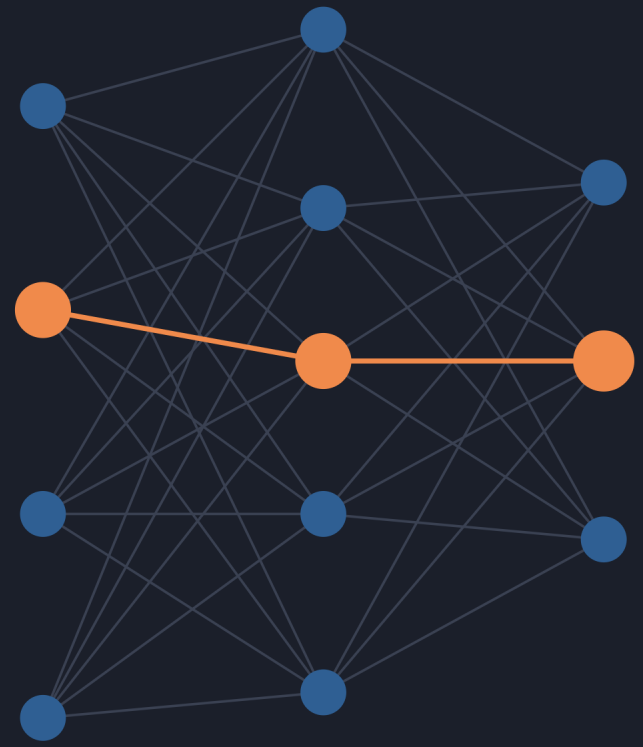
L’AI ha sempre una risposta. Ma è quella giusta?

Fiducia, scelte e pensiero critico nell'era dell'intelligenza artificiale



Gianluca Garofalo

PRIMA DI COMINCIARE

Che cosa affidiamo alle macchine



PER SECOLI

I muscoli

Leve, mulini, motori: macchine per fare meno fatica.

→



POI I COMPUTER

Calcoli e memoria

Contare, archiviare, cercare e gestire informazioni.

→



OGGI

Una parte del pensiero

Scrivere, analizzare, suggerire soluzioni. A volte decidere.

Che cosa succede quando ci abituiamo a far ragionare l'AI al posto nostro?

Il percorso di oggi

Cos’è l’AI generativa

Da dove viene, come funziona e cosa non è

Perché ci fidiamo

Una risposta sempre pronta e sempre sicura di sé

Conosce il mondo?

Come impara, che cosa sa e da dove nascono i bias

Usarla con giudizio

Chiedere o delegare, errori convincenti, tre domande per verificare

Nella vita di ogni giorno

Casa, scuola, lavoro e i nostri dati

E noi?

Paure reali e immaginarie, e le scelte che restano nostre

Gli ultimi quattro anni

L'AI non è nata ieri. Ha almeno settant'anni: nel 1950 Alan Turing si chiede se una macchina possa pensare, nel 1956 a Dartmouth nasce il termine «intelligenza artificiale». Poi decenni di regole scritte a mano, i dati portati da internet, il deep learning e, nel 2017, il Transformer. Oggi ci concentriamo su come siamo arrivati fin qui.

2022

ChatGPT porta l'AI generativa nelle mani di tutti

2023

Modelli multimodali: testo e immagini nello stesso modello

2024

Modelli che «ragionano»: elaborano passaggi intermedi prima di rispondere

2024

Entra in vigore l'AI Act, la prima legge europea sull'AI. Si applica per gradi, fino al 2028

2025–26

Agenti: l'AI pianifica, usa strumenti e porta a termine compiti

Che cos'è un agente. Un sistema costruito attorno a un modello: riceve un obiettivo invece di una domanda, lo scompone in passi, usa strumenti come il browser, i file o altri software, controlla il risultato e prosegue fino alla fine del compito.

Diverso dal computer che conosciamo

IL SOFTWARE CHE CONOSCIAMO

Stessa domanda, stessa risposta. Sempre.

Esegue istruzioni scritte da programmatori. Se il risultato è sbagliato, l'errore sta nelle istruzioni e si può trovare.

Calcolatrice, foglio di calcolo, home banking

L'AI GENERATIVA

Stessa domanda, risposte diverse.

Nessuno ha scritto le sue regole: le ha ricavate da enormi quantità di dati. Costruisce ogni risposta in base alle probabilità. Flessibile, ma non garantita.

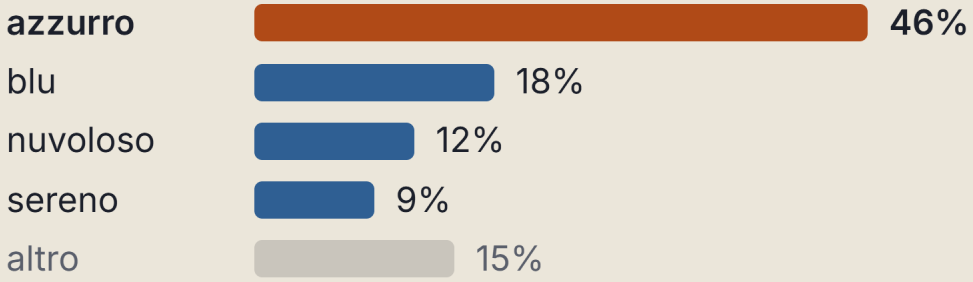
ChatGPT, Claude, Gemini, generatori di immagini

Le diamo la stessa fiducia, ma funziona in un altro modo.

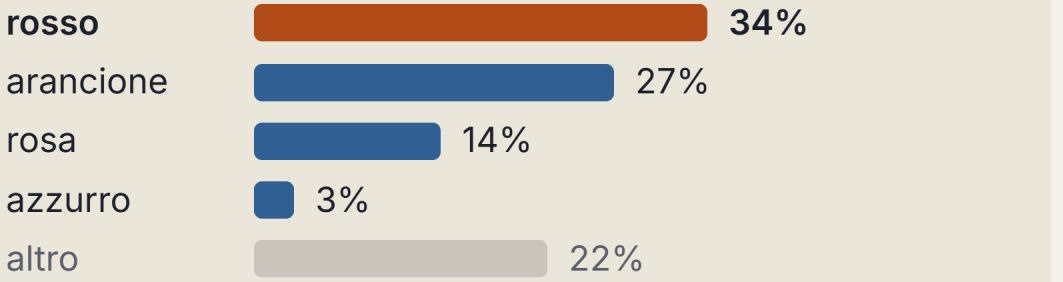
Come funziona: un token alla volta

Token: l'unità su cui lavora davvero il modello. Può essere una parola intera, una parte di parola, una singola lettera o un segno di punteggiatura.

«Il cielo è …»



«Al tramonto il cielo è …»



Contesto: tutto il testo che il modello ha davanti. Bastano due parole in più e le probabilità cambiano completamente.

1. Legge il contesto
2. Calcola le probabilità
3. Sceglie il token
4. La aggiunge e ricomincia

Percentuali illustrative, non misurate su un modello reale

E soprattutto, cosa non è

Non è una mente

Non pensa e non prova emozioni come una persona: elabora testo in base alle probabilità.

Non è un'enciclopedia

Non consulta un archivio di fatti verificati: costruisce ogni risposta «parola» dopo «parola».

Non ha intenzioni proprie

Non vuole nulla da sé: persegue gli obiettivi che le assegniamo noi.

Non sa cosa è vero

Sa cosa è probabile. Spesso coincide con il vero, ma non sempre.

Dal cercare al chiedere

Con un motore di ricerca

- Tanti risultati da confrontare
- Le fonti sono in vista
- La scelta tocca a noi

Con un assistente AI

- Una sola risposta, già pronta
- Le fonti spesso non si vedono
- Risponde sempre, anche quando non sa

Guadagniamo tempo. Il rischio è perdere l'abitudine a confrontare e a scegliere.

Quattro motivi per cui ci fidiamo

Parla come noi

Un linguaggio fluente e ordinato ci sembra un segno di competenza.

Non esita mai

Usa lo stesso tono sicuro per le risposte giuste e per quelle sbagliate.

È sempre disponibile

Paziente, veloce, a qualsiasi ora: non si stanca e non giudica.

Tende a darci ragione

È addestrata a soddisfarci, e spesso asseconda quello che pensiamo già.

Prima ci fidavamo di fonti con un nome e un volto; ora di un sistema che non ne ha. **La fiducia va calibrata:** proporzionata a quanto possiamo verificare.

Come impara: dagli esempi

Come si insegna a una macchina a riconoscere un gatto, senza descriverlo?



1 · Mostrare

Migliaia di foto con l'etichetta giusta: gatto, non gatto.

2 · Sbagliare

Il modello tira a indovinare e misura quanto si è allontanato dalla risposta giusta.

3 · Correggere

Aggiusta di poco i suoi parametri, per sbagliare un po' meno la volta dopo.

Ripetuto milioni di volte, il modello scopre da solo quali forme contano. La regola «gatto» non l'ha scritta nessuno.

Come nasce un modello, in cinque passi



1 · Raccogliere

Libri, siti, articoli e codice: si raccolgono e si ripuliscono.

Persone e software



2 · Leggere

Su miliardi di frasi impara a prevedere il token successivo.

Solo la macchina

Pre-training
Addestramento preliminare



3 · Istruire

Persone scrivono esempi di domande e risposte: impara a seguire le istruzioni.

Persone e macchina

SFT
Supervised Fine-Tuning



4 · Premiare

Persone confrontano due risposte e scelgono la migliore: impara cosa preferiamo.

Persone e macchina

RLHF
Reinforcement Learning from Human Feedback



5 · Verificare

Test di qualità e sicurezza, poi l'uso pubblico sotto osservazione.

Persone e software

Dopo il passo 2 sa **completare testi**. Dopo i passi 3 e 4 sa **conversare** come un assistente.

Che cosa sa davvero del mondo

Conosce i racconti, non le esperienze

Ha letto moltissimo sul mare, ma non ci ha mai fatto il bagno.

Si ferma a una data

Sa ciò che c'era nei suoi dati. Dopo, sa solo quello che trova cercando, se può farlo.

Vede il mondo come lo raccontano i dati

Ciò che è poco raccontato, per lei esiste poco.

Il suo mondo è una **rappresentazione**: fedele quanto lo sono i dati da cui l'ha imparato.

Bias: il modello eredita i nostri squilibri

Un modello impara dai dati. Se i dati sono sbilanciati, lo diventa anche il modello, spesso senza che nessuno se ne accorga.

DATI SBILANCIATI



Lupo o husky?

Nelle foto di addestramento i lupi erano sempre sulla neve. Il modello guardava lo sfondo: un husky sulla neve diventa «lupo».

Università di Washington, 2016

DATI STORICI

Il traduttore

Dal turco, dove «lui» e «lei» si dicono con la stessa parola, il medico diventava sempre uomo e l'infermiere sempre donna.

Google Traduttore, corretto nel 2018

SCELTE DI PROGETTO

Il chatbot che dà sempre ragione

Nel 2025 OpenAI aggiorna ChatGPT dando più peso ai «mi piace» degli utenti. Il modello diventa adulatore e asseconda tutto: l'aggiornamento viene ritirato in pochi giorni.

OpenAI, aprile 2025

Dal farsi aiutare allo smettere di decidere

1 · Mi faccio aiutare

Penso io, l'AI suggerisce.

Chiedo idee per un tema, poi lo scrivo io.

→

2 · Faccio fare

L'AI produce, io controllo e correggo.

Una bozza di email che rileggo e sistemo.

→

3 · Delego tutto

L'AI decide, io mi limito a firmare.

Copio la risposta senza averla letta.

La domanda da farsi: **se smetto di farlo io, che cosa smetto di saper fare?**

5 · QUANDO L'AI SBAGLIA, MA SEMBRA AVERE RAGIONE

Plausibile e vero coincidono spesso. Non sempre.



Un modello calcola ciò che è probabile, sulla base dei dati da cui ha imparato. Da qui nascono i suoi rischi.

Allucinazioni: falso, ma convincente

Il modello produce un'informazione inventata con lo stesso tono sicuro di quelle vere: fonti, date, citazioni, numeri.

Perché succede

- Completa il testo in modo plausibile, senza consultare un archivio di fatti
- È addestrato a rispondere, raramente a dire «non lo so»
- Più la domanda è specifica o rara, più il rischio cresce

Mata v. Avianca, New York, 2023

Due avvocati depositano in tribunale una memoria che cita sei precedenti mai esistiti, generati da ChatGPT.

Il giudice li sanziona con **5.000 dollari**.

Fonte: Mata v. Avianca, Inc., Tribunale distrettuale federale di New York, giugno 2023

Tre domande davanti a ogni risposta

1

Da dove viene?

Posso risalire a una fonte che esiste davvero e che posso aprire?

2

Come lo verifico?

Trovo la stessa informazione in una fonte indipendente?

3

E se fosse sbagliata?

Più alta è la posta in gioco, più serve il controllo di una persona.

Bozze, idee e sintesi: sì. La decisione finale resta a noi.

Cosa cambia a casa, a scuola e nel lavoro

A casa

Assistenti vocali, consigli, ricette, domande di ogni giorno.

Attenzione: a cosa raccontiamo e a cosa lasciamo decidere.

A scuola

Spiegazioni su misura, esercizi, aiuto per chi è in difficoltà.

Attenzione: il compito svolto dall'AI non insegna nulla a chi lo consegna.

Nel lavoro

Bozze, sintesi, traduzioni: meno tempo sulle attività ripetitive.

Attenzione: la responsabilità del risultato resta nostra.

I nostri dati: dove vanno?

Con un chatbot online

- Il testo arriva sui server del fornitore
- Può essere conservato e, a seconda delle impostazioni, usato per l'addestramento
- Fuori dall'Unione Europea valgono anche altre leggi

Con un modello locale



- I dati restano sul nostro computer
- Funziona anche senza connessione
- Richiede un computer adeguato ed è in genere meno potente

Regola pratica: in un chatbot non scrivere ciò che non manderesti per email a un estraneo.

Modelli aperti: Llama, Mistral, Gemma, Qwen · Strumenti: Ollama, LM Studio

Rischi, opportunità, falsi allarmi

Rischi reali

- Disinformazione e falsi realistici (deepfake)
- Delegare troppo e smettere di pensare
- Bias e uso dei nostri dati

Opportunità

- Conoscenza più accessibile a tutti
- Supporto a chi ha difficoltà o disabilità
- Aiuto nella ricerca, nella medicina, nel lavoro

Paure da ridimensionare

- «È cosciente e ha intenzioni proprie»
- «Ci sostituirà in tutto, da domani»
- «O è infallibile, o è inutile»

La paura utile è quella che ci rende più attenti.

9 · E SE LA DOMANDA PIÙ IMPORTANTE RIGUARDASSE NOI?

Che cosa vogliamo continuare a saper fare, decidere e scegliere da soli?

L'AI cambierà molte cose. Quale umanità costruire insieme a lei resta una scelta nostra.

Che cosa abbiamo imparato

Cos’è l’AI generativa

Prevede la «parola» più probabile: non è una mente

Perché ci fidiamo

Parla bene e non esita mai: la fiducia va calibrata

Conosce il mondo?

Conosce i suoi dati, con i loro squilibri

Usarla con giudizio

Da dove viene? Come lo verifico? E se fosse sbagliata?

Nella vita di ogni giorno

Utile ovunque, ma ogni domanda è un dato

E noi?

Rischi reali, non paure da film. Le scelte che contano restano nostre

L’AI ha sempre una risposta. Le domande giuste restano nostre.

Domande?

Rimaniamo in contatto

Gianluca Garofalo

SITO

ggarofalo-dev.github.io

EMAIL

Gianluca.Garofalo@gmail.com



Inquadra il codice per aprire il sito

Come nasce un modello linguistico (Approfondimento)

1	**Raccolta dei dati**	Si raccolgono testi, immagini, codice e altri contenuti per l'addestramento.	**Misto** · persone scelgono le fonti, software le raccoglie
2	**Preparazione dei dati**	Si eliminano duplicati, contenuti indesiderati e dati di scarsa qualità.	**Misto** · persone fissano i criteri, filtri automatici li applicano
3	**Pre-training**	Il modello apprende relazioni statistiche nei dati, ad esempio prevedendo il token successivo.	**Autonomo** · nessun intervento umano sui singoli esempi
4	**Supervised Fine-Tuning (SFT)**	Il modello viene addestrato su esempi di istruzioni e risposte desiderate.	**Misto** · persone scrivono gli esempi, la macchina li apprende
5	**Allineamento alle preferenze**	RLHF, DPO o feedback di altre AI (RLAIF) orientano le risposte. Per i modelli che «ragionano», rinforzo su problemi con soluzione verificabile, come matematica e codice.	**Misto** · persone o altre AI giudicano le risposte, la macchina si adatta
6	**Valutazione e testing**	Si verificano capacità, accuratezza, robustezza e sicurezza con benchmark e test.	**Misto** · test automatici e verifiche di esperti umani
7	**Deployment e monitoraggio**	Il modello viene distribuito e monitorato per individuare problemi e miglioramenti.	**Misto** · sistemi automatici segnalano, persone analizzano e decidono

SFT Supervised Fine-Tuning, addestramento supervisionato su esempi · **RLHF** Reinforcement Learning from Human Feedback, apprendimento per rinforzo dal feedback umano · **DPO** Direct Preference Optimization, ottimizzazione diretta delle preferenze · **RLAIF** Reinforcement Learning from AI Feedback, rinforzo dal feedback di altre AI

In arancio: le fasi di addestramento vero e proprio · **Le fasi da 3 a 6 si ripetono più volte**